Advanced Institute for Artificial Intelligence

Paralelismo

Advanced Institute for Artificial Intelligence – AI2

https://advancedinstitute.ai

Deep Learning HPC

Agenda

- Paralelismo
- Thread
- Níveis de Paralelismo
- MapReduce - Hadoop
- GPU
- Paralelismo para treino e predições

Paralelismo

- Programação concorrente, programação paralela, paralelismo, execução concorrente, programação distribuída, etc
- Nomes diversos para identificar iniciativas para explorar o uso de mais de um recurso computacional para a mesma aplicação
- Fundamental para executar aplicações com demandas que não são atendidas pelos recursos fornecidos por um único computador

Thread

- Em um SO qualquer software é identificado como processo A maioria dos SOs permite que um processo crie uma cópia de si mesmo (Thread)
- Threads são execuções independentes do software que compartilham os mesmos dados da aplicação que a criou
- Criação de uma thread é muito mais rápido que criar um novo processo
- Porque criar threads?
  - Atender requisições simultaneas
    - Requisição web
    - Utilizar diversos hardware ligados a um pc

Thread

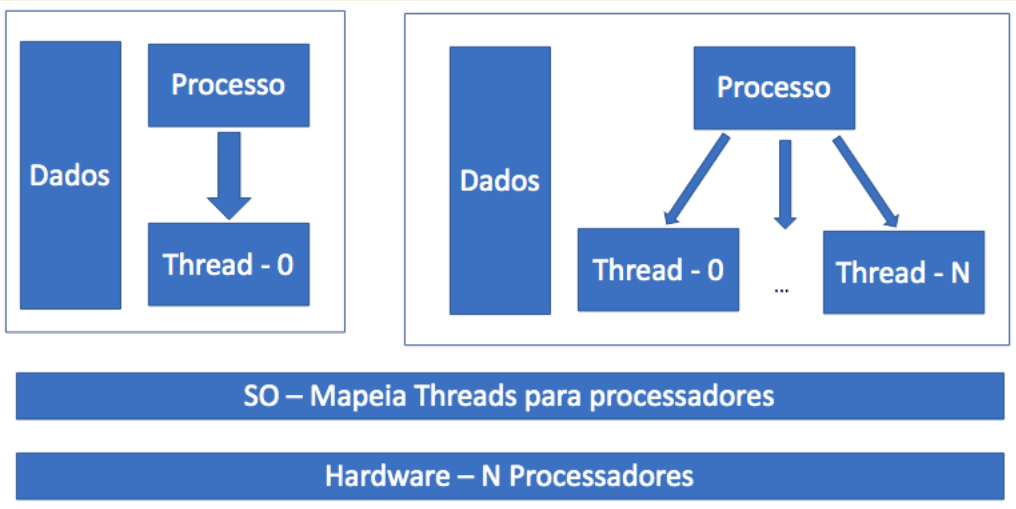
Dados
Processo
Thread - 0
Dados
Processo
Thread - 0
...
Thread - N
SO – Mapeia Threads para processadores
Hardware – N Processadores

Paralelismo

Como explorar esses recursos?

- Para utilizar arquiteturas paralelas é necessário dividir a aplicação em tarefas independentes
  - Para isso podemos dividir o processamento em processos e/ou threads e submeter para execução
  - O SO fará o mapeamento dos processos e threads para os recursos disponíveis
- As tarefas podem possuir algum nível de dependência, de tal forma que, uma tarefa pode necessitar de dados produzidos por outra tarefa antes de entrar em execução
  - Isso deve ser controlado pelo desenvolvedor diretamente

Paralelismo

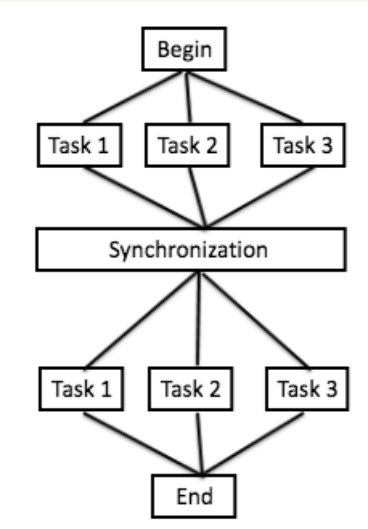

Desafios do paralelismo:

- No nível do software a paralelização deve considerar as sincronizações entre as tarefas
- Quanto ao uso do hardware é necessário traçar estratégias para utilizar de modo eficiente cada recurso de otimização de desempenho
- Obter melhorias de desempenho

Introdução a HPC

Aplicações de Aprendizagem Profunda (Deep Learning) normalmente são computacionalmente intensivas

- Tarefas computacionalmente intensivas em Deep Learning:
  - Busca por hiperparâmetros
  - Treino de modelo
  - Prototipação de modelos
  - Predições em lote
- Quanto mais rápido uma aplicação de aprendizagem profunda é executada, ainda que com um ganho não tão expressivo, apresenta impacto alto no trabalho dos especialistas desse domínio

Introdução a HPC

- Um computador paralelo é um sistema de computador que usa vários elementos de processamento simultaneamente de maneira cooperativa para resolver um problema computacional
- O processamento paralelo inclui técnicas e tecnologias que permitem calcular em paralelo
  - Hardware, redes, sistemas operacionais, bibliotecas paralelas, linguagens, compiladores, algoritmos, ferramentas,...
- O paralelismo é natural
  - Problemas de computação diferem em nível / tipo de paralelismo

Introdução a HPC

Arquiteturas computacionais oferecem:

- ☐ múltiplos nós
- ☐ múltiplos processadores
- ☐ múltiplos co-processadores

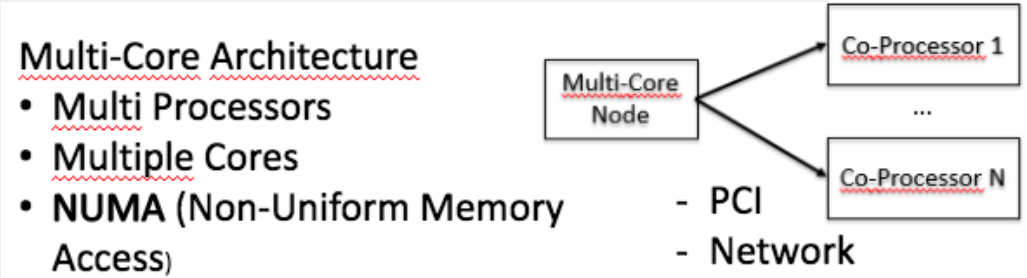

Uma forma de montar uma arquitetura computacional paralela é unificar diversos processadores idênticos

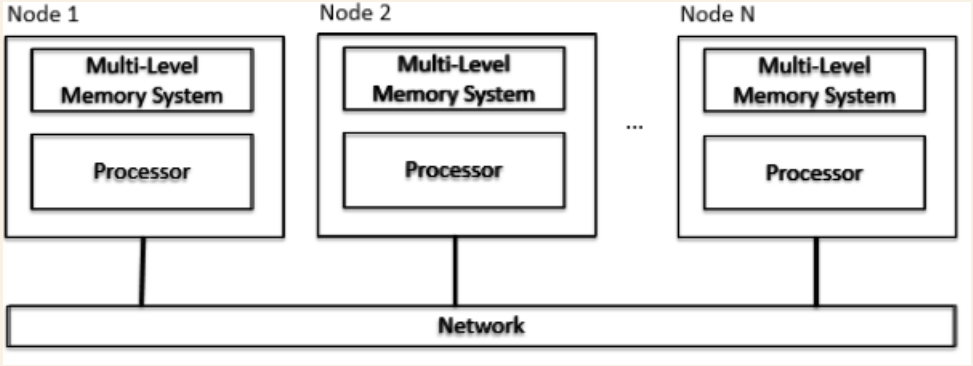

Paralelismo

Outra forma de montar uma arquitetura computacional paralela é unificar diversos processador que podem ser diferentes entre si (Arquiteturas Heterogêneas)

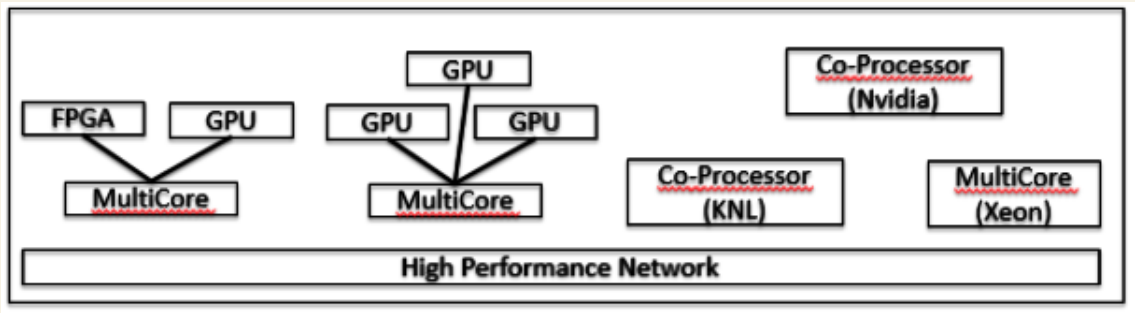

Níveis de paralelismo

- Paralelismo no nível de instrução
  - Mecanismos do processador para aumentar o desempenho
- Paralelismo no nível de dados(Vetorização)
  - Execucão de mais de instrução identicas em paralelo para conjuntos distintos de dados, utilizando registradores vetoriais do processador
  - Vetorização em geral é combinada com técnicas de acesso eficiente utilizando múltiplos níveis de memória (cache)

Níveis de paralelismo

- Paralelismo no nível de tarefa (Thread) OpenMP
  - Múltiplas threads sendo executadas em paralelo
- Paralelismo no nível de processo
  - Mesmo programa em diferentes computadores coordenado a execução por troca de mensagens pela rede (MPI)
- Offload
  - Dividindo o processamento entre o processador e um ou mais co-processadores, como GPU por exemplo

Níveis de Paralelismo

Os níveis de paralelismos podem ser usados de modo combinado por uma única aplicação

O paralelismo pode ser controlado por recursos elementares ou por bibliotecas de alto nível

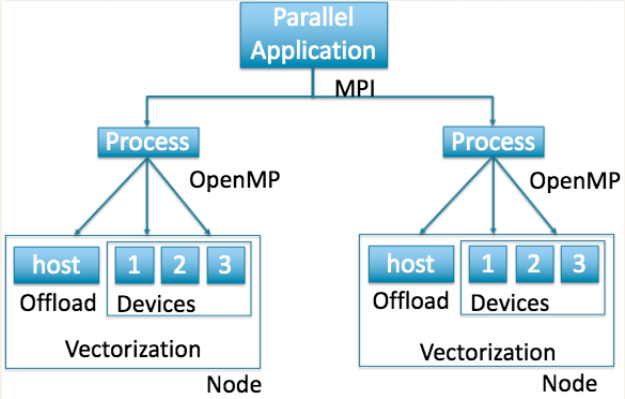

Paralelismo em Python

Barreiras para explorar paralelismo em python

- Python utiliza um componente chamado GIL (Global Interpreter Lock) para proteger chamadas simultaneas a um mesmo objeto na memória
- Embora evite diversos problemas durante a execução, que podem não ser facilmente detectados apenas olhando o código. O GIL inibe o uso de threads
- Na prática uma programa multi thread em python executa sequencialmente

Paralelismo em Python

Barreiras para explorar paralelismo em python

- Uma estratégia possível é utilizar multiprocessamento, no lugar de multi threading
  - Custo de criação e destruição de processo pode ser alto
- Realizar chamadas a bibliotecas externas que por si executando em múltiplas threads
- Implementar o código multi-thread em C e linkar com código python usando cython

Paralelismo em Python

Explorando paralelismo para aprendizagem de máquina

- Ferramentas de aprendizagem de máquina em geral exploram paralelismo, em todos os níveis apresentados
- Ambientes de nuvem podem ser explorados para delegar parte da carga de trabalho
- Escolha de recursos adequados para execução de cada modelo, também pode ser explorado
  - Exemplo, utilizar recursos com GPU para treino de redes neurais

Paralelismo em Python

Frameworks como Spark, Hadoop entre outros podem ser usados para executar o processo completo de aprendizagem de máquina de modo eficiente

- Explorando paralelismo, co-processadores, execução em ambiente de nuvem
- Esses frameworks exploram
  - Execução de modelos
  - Processamento dos dados de modo distribuído
  - Uso de memória RAM para inibir atrasos por transferência em disco

Map Reduce

Modelo de paralelismo desenvolvido pela Google para processamento de grandes volumes de dados [1]

- Baseia-se na idéia de usar apenas duas funções para facilitar a execução paralela
- Modelo mais rígido de paralelismo, mas facilita a otimização de desempenho
- A implementação é proprietárias mas existe uma implementação pública do modelo Hadoop [2]

[1] Jeffrey Dean and Sanjay Ghemawat. 2004. MapReduce: simplified data processing on large clusters. In Proceedings of the 6th conference on Symposium on Opearting Systems Design Implementation

[2] http://hadoop.apache.org

Map Reduce

- Essa abordagem permiteo mapear fragmentos de dados de entrada a uma chave identificadora, e entao processar todos os fragmentos que compartilhem a mesma chave.
- Se a quantidade de dados for grande, pode ser dividido para a execucao de diversas funcoes Map ao mesmo tempo, em paralelo.
- Podemos aplicar separadamente as funcoes Map e Reduce a um conjunto de dados.
- Um sistema de arquivos especial chamado HDFS permite mapear diferentes partes de uma mesmo arquivo em diferentes sistemas de memória volátil em diversas unidades de processamento

Map Reduce

Estratégia

- A funções Map recebe um conjunto de dados e retorna um conjunto chave-valor
- A função reduce recebe esse conjunto chave-valor, aplica uma operação e retorna outro conjunto chave-valor
- A idéia é que tanto o map quanto o reduce sejam operações simples que possam ser paralelizadas

Map Reduce

Um exemplo clássico de uso do Hadoop é a aplicação para contar palavras únicas em um arquivo de texto

- A funções Map le cada linha e gera uma tupla palavra,1
- A função reduce le todas as tuplas e cria novas tuplas com o somatório de cada palavra encontrada
- O map a medida que le o texto já gera as tuplas
- O reduce a medida que le as tuplas, mesmo que diferentes nós, consegue fazer a soma
  - No caso do reduce, a medida que as somas são realizadas para cada nó, é possível acumular hierarquicamente

A estratégia é simples, porém muito complexa de implementar para outros casos

Outros modelo surgiram com o objetivo de facilitar o uso desse modelo

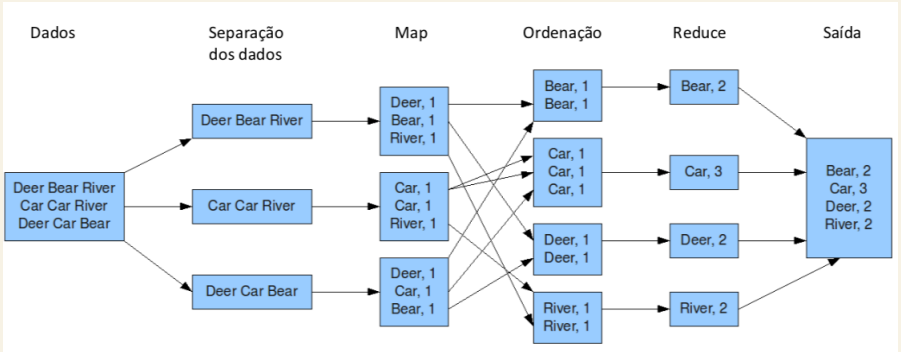

Spark

Apache Spark [3] é uma ferramenta de Big Data

Tem como objetivo processar grandes volumes de dados em clusters de computadores

Baseado em Map Reduce

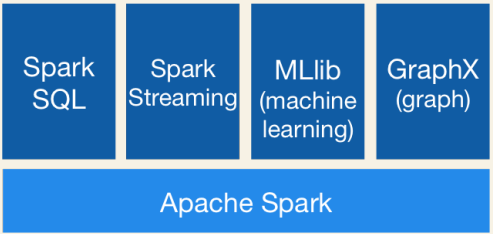

[3] https://spark.apache.org/

Spark

O recurso básico do Spark é o RDD (Resilient Distributed Datasets)

- Unidade fundamental de dados em Spark
- Resiliente: se dados na memória são perdidos, podem ser recriados
- Distribuído: armazenados na memória por todo o cluster
- Datasets: dados iniciais podem vir de um arquivo ou ser criado programaticamente
- Muitos programas Spark se baseiam na manipulação de RDDs

MLlib

- Módulo que implementa algoritmos de machine learning e recursos para manipular dataframe
- Similar ao Scikit-learn, oferece várias implementações e permite testar vários algoritmos com o mesmo dataframe
- Otimizado para desempenho e paralelismo em cluster